基于 TimerXL 的小样本跨工况刀具磨损预测：时间尺度增强与 KNN 增量残差检索

艾思博

March 2026

1 摘要

在工业刀具磨损预测中，受限于高昂的标注成本与跨工况带来的数据分布偏移，模型常在极小样本（few-shot）下面临泛化失稳。特别是不同工况导致的时间尺度错位，易使现有基础模型在晚期高频磨损阶段出现严重的‘增量低估偏差’。为此，本文提出一种基于 TimerXL 的时序预测两阶段增强框架。首先，设计训练时多步幅增强策略（TMA），利用局部磨损速率对缓速退化段进行因果降采样，在零泄露前提下缓解退化节奏不一致，提升后续检索空间的语义一致性。其次，引入 K 近邻增量残差检索模块（KNN-DRR），从专属库中召回经 TMA 对齐的历史相似轨迹，动态修正 TimerXL 输出的未来磨损增量残差，显式补偿晚期低估偏差。

在 PHM2010 数据集的三折留一工况交叉验证实验中，本文方法展现出显著的预测优势。相比 TimerXL 基线，所提框架在代表性困难折（c1,c4→c6）上的全曲线平均绝对误差（MAE）由 13.40 μm 降至 3.21 μm，相对下降约 76.1%；整体三折平均 MAE 由 8.77 μm 降至 3.18 μm。尤为关键的是，在高频磨损阶段，late-stage MAE 由 32.43 μm 进一步降至 5.78 μm。实验结果表明，所提框架能够有效缓解跨工况时间尺度错位，并显著修正小样本条件下晚期未来磨损增量的系统性低估。

关键词：刀具磨损预测；跨工况泛化；时序基础模型；检索增强预测；残差修正；小样本学习

2 引言

刀具磨损预测是智能制造系统中保障加工质量、生产效率与运行安全的关键基础环节 [1, 2, 3, 4]。机械加工广泛应用于航空航天、汽车制造、模具加工等高端制造场景，而刀具作为直接作用于工件的核心执行部件，持续承受切削力、摩擦与热载荷作用，其服役状态对加工过程具有决定性影响 [1, 2, 4]。由于材料去除过程本身具有强接触、强摩擦和高温特征，刀具在加工过程中不可避免地发生持续退化，其中以后刀面磨损最为典型。随着磨损不断累积，刀具切削性能将逐步下降，进而导致加工表面质量恶化、尺寸精度下降，并可能诱发崩刃、断裂以及异常停机等问题，严重影响制造系统的生产效率、设备可靠性与现场安全 [1, 2, 3]。

鉴于刀具磨损对制造过程的重要影响，围绕刀具状态监测与磨损预测的研究已成为预测性维护与工业智能领域的热点方向 [3, 4]。与一般的时间序列回归任务不同，刀具磨损并非仅随时间平滑推进的单调过程，而是受到切削速度、进给率、切削深度、工件材料及刀具自身状态等多因素共同作用的非均匀退化过程 [5, 6, 7]。不同工况下，刀具往往表现出明显不同的磨损演化节奏：相同切削步数并不对应相同磨损阶段，不同刀具在早期磨合、中期稳定磨损与晚期快速失效阶段也常呈现出差异显著的增长速率 [8, 9, 10, 11]。因此，模型不仅要学习磨损值本身的变化规律，还必须刻画跨工况条件下退化节奏不一致所导致的时间尺度错位问题。这种由工况变化引发的阶段错位和退化速率漂移，使得刀具磨损预测在 few-shot 与 cross-condition 条件下远比常规时序预测更具挑战性 [8, 10, 6, 12, 11]。

上述困难在真实工业部署中会进一步放大。一方面，新工况往往只能提供极少量甚至不完整的生命周期样本，难以支撑依赖大规模标注数据的监督建模范式 [10, 12, 11]；另一方面，刀具磨损标签通常需要依赖高精度测量设备和人工检测获得，采集过程成本高、周期长，并且需要专业经验支持，难以在每一种新工况下重复构造充足的标注集 [1, 2, 10]。已有研究指出，工况变化不仅会引起输入信号分布的改变，还会改变刀具退化趋势本身，使得训练阶段建立的经验风险最小化假设在实际部署中难以成立 [7, 8, 9, 13]。对于刀具磨损预测而言，这意味着模型必须在极小样本条件下同时处理样本稀缺、分布偏移和退化节奏失配三类问题，这构成了当前工业场景中最具现实性的技术瓶颈之一 [10, 6, 11]。

针对刀具磨损预测，现有研究已提出大量数据驱动方法，包括基于特征工程与传统机器学习的监测方法、基于卷积网络、循环网络与 Transformer

的深度时序建模方法，以及面向变工况场景的迁移学习、领域适应和元学习方法 [14, 15, 16, 17, 18, 19, 20, 21, 7, 9, 22, 23, 10, 12, 11]。这些方法在固定工况或训练测试分布相近的设定下取得了较好效果，但在跨工况场景中仍存在明显局限。传统监督式预测通常默认训练数据与部署阶段数据服从相同或相近分布，难以应对工况变化引起的结构性偏移；迁移学习与领域适应方法虽然尝试缩小不同工况之间的表示差异，但更多关注整体分布对齐，而对 “相同时间步不对应相同磨损阶段” 这一退化过程层面的错位问题关注不足 [7, 8, 9, 22, 23, 13]；一些 few-shot 或元学习方法尝试缓解小样本困难，但当目标工况的退化节奏与训练工况显著不一致时，仍容易出现支持信息不足、预测过度平滑及晚期失稳等问题 [10, 6, 12, 11]。现有方法尚未充分解释并有效修复跨工况刀具磨损预测中由时间尺度错位引发的阶段性泛化退化。

近年来，以 TimerXL 为代表的时序基础模型为小样本工业预测提供了更强的预训练表征能力，使模型能够在有限样本条件下获得较好的时序特征提取效果 [24, 25]。然而，在极小样本跨工况设定下，仅依赖基础模型微调仍不足以彻底解决刀具磨损预测中的结构性误差。当目标工况的磨损演化节奏与训练工况不一致时，模型容易收缩为过度平滑的平均化预测，尤其在晚期高磨损区间难以准确刻画快速增长的局部增量变化，从而表现为未来磨损增量的系统性低估。该问题在 hardestfold 场景下尤为突出，说明当前瓶颈并不只是模型容量不足或特征数量不够，而是跨工况退化阶段错位与晚期残差偏差未被显式建模和修正。因此，如何在保持零泄露协议边界的前提下缓解时间尺度错位，并进一步对晚期系统性低估进行针对性补偿，成为提升小样本跨工况刀具磨损预测性能的关键。

为解决上述问题，本文构建了一种以 TimerXL 为预测底座的两阶段增强框架 [25]。首先，提出训练时多步幅增强策略（Train-time Multi-stride Augmentation, TMA），仅利用训练折窗口内局部磨损速率的统计信息，对缓速退化区段执行因果式降采样增强，以缓解不同工况之间退化节奏不一致带来的时间尺度错位，并提升表示空间的可比性。进一步地，提出 K 近邻增量残差检索模块（KNN-based Delta Residual Retrieval, KNN-DRR），通过在训练专属检索库中召回经 TMA 增强后的历史相似轨迹，对基础预测头输出的未来磨损增量残差进行动态修正，从而显式补偿 late-stage 的系统性低估偏差。与将基础模型、时间增强和检索修正并列视为独立创新不同，本文强调三者之间的层级关系：TimerXL 提供基础时序表征能力，TMA 用于

改善跨工况表示可比性，KNN-DRR 则作为主修复机制，针对 hardestfold 中最突出的晚期增量低估问题进行显式校正。

本文的主要贡献可概括为以下三点。第一，面向 few-shot cross-condition 刀具磨损预测任务，识别并刻画了由跨工况退化节奏差异引起的时间尺度错位问题，以及其在 hardest fold 上表现为 late-stage 系统性低估的关键失效模式。第二，提出训练时多步幅增强策略 TMA，在严格零泄露前提下利用训练折局部磨损速率统计提升不同工况下表示空间的可比性，为后续检索修正提供更稳定的基础。第三，提出 KNN-DRR，通过训练专属检索库对未来磨损增量残差进行动态回拉，显式修复基础模型在晚期阶段的系统性低估偏差，并在 PHM2010 数据集上的三折跨工况实验中验证了该框架的有效性与稳健性 [26]。

3 方法

本文考虑 PHM2010 数据集上的 few-shot cross-condition 刀具磨损预测任务。给定长度为 96 的历史观测窗口，模型需要预测未来 16 个时间步的刀具磨损序列。该任务的主要困难并不在于一般意义上的特征不足，而在于不同工况下磨损推进速率存在显著差异。相同的切削步数在不同工况中往往对应不同的实际磨损阶段，这会导致表征空间中的时间尺度错位，并进一步使基础预测器在晚期阶段系统性低估未来磨损增量。围绕这一问题，本文的方法层级被明确划分为三部分：TimerXL 作为预训练时序骨干网络提供基础表示与基础预测，TMA 作为训练期的辅助时间尺度增强机制提升跨速率样本的表示可比性，KNN-DRR 则作为主创新模块，通过检索历史相似轨迹对未来磨损增量残差进行显式修正。

3.1 TimerXL 骨干预测器

本文采用 TimerXL 作为基础时序预测平台。需要强调的是，TimerXL 在本文中承担的是骨干网络角色，而非主要创新来源。对于输入历史窗口，TimerXL 输出未来 16 步的基础磨损预测，同时生成可供后续检索使用的共享表示。该设计使得同一套时序表示既服务于监督预测头，也服务于后续的相似轨迹检索。换言之，TimerXL 提供的是一个稳定的表示与预测平台，但它本身并不直接解决跨工况时间尺度错位，也不能单独消除晚期未来增量低估这一结构性误差。正式主结果中的 head-only 结果正用于刻画这一基

础平台在无额外机制时的可达性能边界。

3.2 TMA：训练期时间尺度增强

为缓解跨工况磨损速率差异带来的时间尺度错位，本文在训练阶段引入 TMA。TMA 的作用并不是修改验证或测试流程，而是在训练期对历史窗口实施多步长增强，使骨干网络在参数更新过程中接触到更丰富的时间推进视角。按照正式协议，训练阶段允许采用 ‘stride 1,2‘ 的随机增强，而验证与测试始终固定为 ‘stride=1‘。因此，TMA 的定位应被理解为一种严格局限于训练阶段的辅助增强机制，它通过模拟不同磨损推进速率下的历史观测形态，提升共享表示在跨工况条件下的可比性。

从机制上看，TMA 并不直接产生最终预测，而是改善后续检索所依赖的表示空间。图 6 与表 6 的结果表明，TMA 能够在不触碰外层测试工况的前提下，提高晚期检索的可用性，并为后续的残差修正提供更具语义一致性的候选邻居。因此，本文将 TMA 视为 KNN-DRR 的前置条件而非终点：它解决的是“如何让不同磨损速率下的样本在表示空间中更可比较”，而不是“如何单独完成最终磨损预测”。

3.3 KNN-DRR：基于检索的磨损增量残差修正

本文的核心创新是 KNN-DRR。该模块并不试图替代 TimerXL 的基础预测，而是在 TimerXL 已给出未来磨损序列初值的基础上，进一步修正未来磨损增量的残差。其出发点在于：在 few-shot cross-condition 设定下，基础预测器更容易在晚期阶段给出偏保守的未来增量，从而形成系统性的 underestimation。相比直接重新拟合整条未来曲线，更稳妥的做法是把问题转化为“当前样本的未来磨损增量相对基础预测仍缺多少”，再利用历史相似轨迹来估计这一残差。

具体而言，在每个外层折中，本文仅使用训练工况中的样本构建检索库。对于每个训练窗口，先由 TimerXL 提取共享表示，再计算该窗口到未来预测终点之间的真实磨损增量，并将“表示—增量”对保存到检索库中。完成训练后，模型参数和检索库均被冻结。对于测试窗口，首先由 TimerXL 产生基础预测与共享表示，然后在训练工况检索库中执行最近邻检索，得到若干历史相似轨迹的未来磨损增量估计。最后，KNN-DRR 并不是直接用检索结果替换基础预测，而是将检索得到的未来增量与基础预测隐含的未

来增量进行比较，以残差修正的方式更新最终预测。由此，骨干网络负责给出整体趋势，检索模块负责在最容易出现结构性偏差的位置进行定向纠偏。

这种设计保留了基础模型的全局时序建模能力，也避免了纯检索方法在整体曲线稳定性上的不足。表 5 的检索模式消融结果进一步说明，直接使用绝对值投票并不能稳定形成最优正式结果，而基于未来增量残差的修正能够更有效地对抗 late-stage 的结构性低估。因此，KNN-DRR 的作用应被描述为 “future wear increment residual correction”，而不是 “retrieval replaces the backbone prediction”。

3.4 Zero-leakage 边界

本文在方法设计上严格遵守 zero-leakage 边界。首先，训练、验证与测试在外层三折 LOCO 协议下严格分离，外层测试工况在训练过程中被完全封存。其次，TMA 只作用于训练期数据增强，验证与测试阶段不进行任何自适应时间尺度处理。再次，KNN-DRR 的检索库仅由训练工况样本构建，测试工况的未来标签不会参与模型训练、特征筛选、参数确定或检索库构建。最后，外层测试仅在模型权重和检索超参数完全冻结后执行一次，用于最终离线评估。基于上述边界，本文的正式结果不包含 outer-test tuning，也不依赖任何未来感知对齐策略。

3.5 Inner LOSO 训练内选参协议

为避免在 outer test fold 上进行 retrieval 参数选择，本文采用 inner leave-one-source-out（inner LOSO）协议，在训练工况内部完成 train-only 超参数确定。对于每个外层折，设两个源工况分别为 A 和 B，则在内层验证中先使用 A 构建检索库并以 B 作为验证目标，再交换角色使用 B 构建检索库并以 A 作为验证目标。通过这种方式，参数选择过程能够在不接触外层测试工况的前提下，保留 cross-condition gap、wear-rate mismatch 以及 residual correction 的真实需求。本文在这一 inner LOSO 协议下评估候选的 k、$beta$ 与 $late_q$ 组合，并在全部内层验证任务上聚合误差后，确定单一的全局固定配置 k=10、$beta$=0.7、$late_q$=0.0。该配置在正式外层测试前即被锁定，随后用于全部三折 outer test 的一次性评估。

综上，本文的方法结构可以概括为：TimerXL 提供基础时序表示与基础预测，TMA 在训练阶段改善跨速率条件下的表示可比性，KNN-DRR 利用训练工况中的历史相似轨迹对未来磨损增量残差进行修正。三者之间并

非并列创新关系，而是具有明确层级：TimerXL 是平台，TMA 是辅助增强，KNN-DRR 是主创新。

4 实验设置

本文在 PHM2010 刀具磨损预测数据集上评估所提方法。该数据集包含三个典型工况 ‘c1‘、‘c4‘ 和 ‘c6‘，每个工况均对应一条完整的刀具磨损演化轨迹，单条轨迹长度均为 315 个时间步，磨损标签以微米为单位给出。由于不同工况下切削条件不同，同一切削步对应的实际磨损阶段并不一致，因此 PHM2010 是检验跨工况时间尺度错位与晚期磨损低估问题的合适基准。按照本文锁定的正式协议，我们采用三折 leave-one-condition-out（LOCO）评估：fold1 为 ‘c1,c4 -> c6‘，fold2 为 ‘c4,c6 -> c1‘，fold3 为 ‘c1,c6 -> c4‘。在每个外层折中，两个源工况用于训练与验证，剩余一个工况被完全封存并作为最终测试对象。

训练与评估边界遵循严格的 clean protocol。骨干网络训练阶段只访问源工况样本，并在源工况内部执行训练/验证划分；训练过程中的模型选择基于验证误差完成，不进行任何 epoch 级测试监控。TMA 仅在训练阶段作用于历史窗口增强，对应的训练步长为 ‘stride 1,2‘，其中额外步长以随机方式作用于训练批次；验证与测试始终保持 ‘stride=1‘。因此，测试工况在整个训练和模型选择过程中始终被封存，只有当骨干网络参数完全冻结后才会被用于离线评估。所有正式结果均采用这一协议，正式指标不混入历史 blocked 结果或 exploratory 分支结果。

本文的评价指标为全曲线平均绝对误差（fullcurve raw MAE）与全曲线均方根误差（fullcurve raw RMSE），单位均为微米。对于机制分析，本文还报告代表性困难场景和分阶段误差分解，包括 early、mid、late 三个阶段的 MAE、RMSE、mean residual 以及低估比例。这些附加指标并不改变主结果的判断标准，而是用于解释正式主结果为何成立，尤其用于验证 “late-stage future-increment underestimation 是主要结构性误差来源” 这一机制性主张。

在 retrieval 参数选择方面，本文采用 train-only 的 inner leave-one-source-out（inner LOSO）协议，而不是在 outer test fold 上进行调参。具体来说，对于每个外层折，设两个源工况分别为 A 和 B，则先使用 A 构建检索库并以 B 作为内层验证目标，再交换 A 与 B 的角色重复一次。所有

候选的 k、$beta$ 与 $late_q$ 组合均只在这些内层 cross-condition 验证任务上比较，外层测试工况不参与任何形式的参数选择。完成内层验证后，我们聚合全部 inner splits 的误差并确定全局固定配置，然后在三折 outer test 上各自仅评估一次。按照当前正式主线的锁定结果，最终外层测试统一使用 k=10、$beta$=0.7、$late_q$=0.0。

在这一协议下，外层测试与内层选参的关系需要明确区分。inner LOSO 的任务是模拟“源工况之间的跨工况泛化”，以便在不触碰 outer test 的前提下选择更接近真实应用场景的检索超参数；outer test 的任务则是对冻结后的完整方法进行最终一次性评估。换言之，inner LOSO 只决定参数，不提供正式主结果；正式主结果完全来自 outer LOCO 测试。基于这一 clean protocol，本文最终形成三条可直接比较的正式结果链：TimerXL head-only、TimerXL + TMA，以及 TimerXL + TMA + KNN-DRR。其中，KNN-DRR 在 inner LOSO 选出的固定配置下取得三折平均 MAE 3.1784μm 和平均 RMSE3.9763μm，作为本文主结果的唯一正式来源。

参考文献

[1] Roberto Munaro, Aldo Attanasio, and Antonio Del Prete. Tool wear monitoring with artificial intelligence methods: A review. *Journal of Manufacturing and Materials Processing*, 7(4):129, 2023.

[2] Yaonan Cheng, Xiaoyu Gai, Rui Guan, Yingbo Jin, Mengda Lu, and Ya Ding. Tool wear intelligent monitoring techniques in cutting: a review. *Journal of Mechanical Science and Technology*, 37:289–303, 2023.

[3] Danil Yu Pimenov, Andres Bustillo, Szymon Wojciechowski, Vishal S. Sharma, Munish K. Gupta, and Mustafa Kuntoğlu. Artificial intelligence systems for tool condition monitoring in machining: analysis and critical review. *Journal of Intelligent Manufacturing*, 34:2079–2121, 2023.

[4] Haoyuan Zhang, Shanglei Jiang, Defeng Gao, Yuwen Sun, and Wenxiang Bai. A review of physics-based, data-driven, and hybrid models for tool wear monitoring. *Machines*, 12(12):833, 2024.

[5] Changsen Yang, Jingtao Zhou, Enming Li, Huibin Zhang, Mingwei Wang, and Ziqiu Li. Milling cutter wear prediction method under variable working conditions based on LRCN. *The International Journal of Advanced Manufacturing Technology*, 121:2647–2661, 2022.

[6] Yilin Li, Jinjiang Wang, Zuguang Huang, and Robert X. Gao. Physics-informed meta learning for machining tool wear prediction. *Journal of Manufacturing Systems*, 62:17–27, 2022.

[7] Jianliang He, Yuxin Sun, Chen Yin, Yan He, and Yulin Wang. Cross-domain adaptation network based on attention mechanism for tool wear prediction. *Journal of Intelligent Manufacturing*, 34:3365–3387, 2023.

[8] Changqing Liu, Yingguang Li, Jingjing Li, and Jiaqi Hua. A meta-invariant feature space method for accurate tool wear prediction under cross conditions. *IEEE Transactions on Industrial Informatics*, 18(2):922–931, 2022.

[9] Yumeng Zhu, Yanyang Zi, Jing Xu, and Jie Li. An unsupervised dual-regression domain adversarial adaption network for tool wear prediction in multi-working conditions. *Measurement*, 200:111644, 2022.

[10] Dongdong Wang, Qingyang Liu, Dazhong Wu, and Liqiang Wang. Meta domain generalization for smart manufacturing: Tool wear prediction with small data. *Journal of Manufacturing Systems*, 62:441–449, 2022.

[11] Xuandong Mo, Xiaofeng Hu, Andong Sun, and Yahui Zhang. A meta-learning method for smart manufacturing: Tool wear prediction using hybrid information under various operating conditions. *Robotics and Computer-Integrated Manufacturing*, 91:102846, 2025.

[12] Xuandong Mo, Andong Sun, Teng Wang, and Xiaofeng Hu. Few-shot learning for smart manufacturing: Tool wear prediction using out-of-domain data based on meta-learning. In *2023 IEEE 19th International Conference on Automation Science and Engineering (CASE)*, pages 1–6. IEEE, 2023.

[13] Yifan Wang, Jie Gao, Wei Wang, Jinsong Du, and Xu Yang. A novel method based on deep transfer learning for tool wear state prediction under cross-dataset. *The International Journal of Advanced Manufacturing Technology*, 131:171–182, 2024.

[14] Zhaopeng He, Tielin Shi, and Jianping Xuan. Milling tool wear prediction using multi-sensor feature fusion based on stacked sparse autoencoders. *Measurement*, 190:110719, 2022.

[15] Kang Wang, Aimin Wang, Long Wu, and Guangjun Xie. Machine tool wear prediction technology based on multi-sensor information fusion. *Sensors*, 24(8):2652, 2024.

[16] Tanner Jones and Yang Cao. Tool wear prediction based on multisensor data fusion and machine learning. *The International Journal of Advanced Manufacturing Technology*, 137:5213–5225, 2025.

[17] Weixin Xu, Huihui Miao, Zhibin Zhao, Jinxin Liu, Chuang Sun, and Ruqiang Yan. Multi-scale convolutional gated recurrent unit networks for tool wear prediction in smart manufacturing. *Chinese Journal of Mechanical Engineering*, 34:53, 2021.

[18] Xianli Liu, Shaoyang Liu, Xuebing Li, Bowen Zhang, Caixu Yue, and Steven Y. Liang. Intelligent tool wear monitoring based on parallel residual and stacked bidirectional long short-term memory network. *Journal of Manufacturing Systems*, 60:608–619, 2021.

[19] Changsen Yang, Jingtao Zhou, Enming Li, Mingwei Wang, and Ting Jin. Local-feature and global-dependency based tool wear prediction using deep learning. *Scientific Reports*, 12:14574, 2022.

[20] Xingang Xie, Min Huang, Yue Liu, and Qi An. Intelligent tool-wear prediction based on informer encoder and bi-directional long short-term memory. *Machines*, 11(1):94, 2023.

[21] Sumei Si, Deqiang Mu, and Zekai Si. Intelligent tool wear prediction based on deep learning PSD-CVT model. *Scientific Reports*, 14:20754, 2024.

[22] Pengfei Zhang, Dong Gao, Dongbo Hong, Yong Lu, Zihao Wang, and Zhirong Liao. Intelligent tool wear monitoring based on multi-channel hybrid information and deep transfer learning. *Journal of Manufacturing Systems*, 69:31–47, 2023.

[23] Wen Hou, Jiachang Wang, Leilei Wang, and Song Zhang. Novel tool wear prediction method based on multimodal information fusion and deep subdomain adaptation. *Mechanical Systems and Signal Processing*, page 112128, 2024. Available online 12 November 2024.

[24] Yong Liu, Haoran Zhang, Chenyu Li, Xiangdong Huang, Jianmin Wang, and Mingsheng Long. Timer: Generative pre-trained transformers are large time series models. In *Proceedings of the 41st International Conference on Machine Learning*, volume 235 of *Proceedings of Machine Learning Research*, pages 32369–32399. PMLR, 2024.

[25] Yong Liu, Guo Qin, Xiangdong Huang, Jianmin Wang, and Mingsheng Long. Timer-xl: Long-context transformers for unified time series forecasting. In *International Conference on Learning Representations*, 2025. OpenReview poster; published 22 January 2025.

[26] The Prognostics and Health Management Society. 2010 phm society conference data challenge, 2010. Accessed: 2026-04-01.